

비디오 배경음악 엔드투엔드 프레임워크 : 비디오 콘텐츠를 위한 자동 캡셔닝 및 음악 생성

이재건, 권태준, 최장훈
경북대학교 데이터사이언스 대학원

Abstract

- 비디오 장면에 맞는 배경 음악 자동 생성 프레임워크 제안
- 멀티모달 기반 비디오 캡셔닝 모델을 활용해 장면 설명
- 생성된 캡션을 입력으로 사용하여 음악 생성 모델을 통해 배경 음악 생성
- 다양한 분위기의 비디오(여행, 풍경, 공포 등) 7개에 대해 실험 수행
- 데모 결과 QR 코드 제공
- 비디오-음악 매칭을 위한 새로운 멀티모달 생성 파이프라인 제안

Introduction

- 현대 사회에서 비디오 콘텐츠 소비가 급증하고 있음
- 이에 따라 비디오에 어울리는 오디오를 생성하려는 기술 수요가 증가
- 최근 대규모 VLM 모델의 발전으로 자연어 캡션 생성의 정밀도가 향상됨
- 본 연구는 다음의 목적을 가짐
 - 영상의 시각 정보와 감정을 파악
 - 이에 맞는 배경음악을 자동 생성
 - 전체 과정을 엔드투엔드 통합 프레임워크를 제안

Methodology


A. System Architecture

- Video Captioning Module
 - 입력 비디오는 프레임 단위로 분할되어 VLM 모델의 Vision Encoder에 입력
 - Vision Encoder는 시각 특징을 추출하고 이를 Text Tokenizer와 함께 처리하여 자연어 캡션을 생성
- Music Generation Module
 - 생성된 캡션을 YuE 모델의 입력으로 사용
 - 영상의 분위기와 일치하는 배경음악 자동 생성
 - 생성된 음악은 영상과 통합하여 최종 콘텐츠 제공

B. Workflow


- 비디오 프레임을 VideoLLaMA3에 입력
- 비디오의 시각적 내용 및 분위기를 반영한 캡션 생성
- 캡션을 YuE에 입력
- 적절한 배경음악을 생성해 영상과 결합

(우측 그림 참조)



Experimental Results

- 여행/풍경/공포 등 다양한 장르를 가진 7개 비디오에 대해 실험 진행




References

- [1] Zhang, Boqiang; Li, Kehan; Cheng, Zesen; Hu, Zhiqiang; Yuan, Yuqian; et al. "VideoLLaMA 3: Frontier Multimodal Foundation Models for Image and Video Understanding." arXiv preprint arXiv:2501.13106, 2025.
- [2] Yuan, Ruibin; Lin, Hanfeng; Guo, Shuyue; et al. "YuE: Scaling Open Foundation Models for Long-Form Music Generation." arXiv preprint arXiv:2503.08638, 2025. DOI: 10.48550/arXiv.2503.08638
- [3] LeCun, Yann; Bottou, Léon; Bengio, Yoshua; Haffner, Patrick. "Gradient-Based Learning Applied to Document Recognition." Proceedings of the IEEE, 86(11): 2278-2324, 1998. DOI: 10.1109/5.726791



경북대학교
KYUNGPOOK NATIONAL UNIVERSITY



경북대학교 데이터사이언스대학원