


MoE 를 활용한 Xray 객체분류방법론

Jaegun Lee and Janghoon Choi

Department of Data Science and Computer Vision, Kyungpook National University, Daegu, Korea

PROPOSED

Network Structure



Goals

- ConvNeXt-XXLarge [1]와 MoE [2]를 결합해 파라미터와 계산 비용을 줄이면서도 경쟁력 있는 성능을 구현합니다.

Characteristics

- 이미지를 각 ConvNeXt 경로와 MoE 경로로 나누어 특징을 추출합니다.
- ConvNeXt-XXLarge의 일부 레이어만 사용해 모델 크기를 줄였습니다.
- ResNet18의 선택된 레이어와 게이팅 메커니즘으로 상위 k개의 전문가만 활성화해 파라미터를 최소화합니다

- ConvNeXt 출력([B, feature_dim])과 MoE 출력([B, hidden_size])을 결합해 ([B, feature_dim + hidden_size])을 생성합니다.

MoE Introduction

- MoE(Mixture of Experts)는 여러 전문가 네트워크를 활용하여 특정 입력에 대해 최적의 전문가를 선택하는 방식입니다. [2]
 - 본 연구에서는 이미지를 ConvNeXt 경로와 ResNet18 기반 MoE(전문가 10개) 경로로 분리하여 각각 특징을 추출한 뒤, 상위 k=3 전문가의 출력을 ConvNeXt 출력과 결합(concat)해 최종 분류를 수행합니다

EXPERIMENTS

Loss Function

- Cross-Entropy Loss for classification

$$\text{Batch Loss} = \frac{1}{N} \sum_{n=1}^N \text{Loss}^{(n)} = -\frac{1}{N} \sum_{n=1}^N \log \left(\frac{e^{z_y^{(n)}}}{\sum_i e^{z_i^{(n)}}} \right)$$

Results


- Dataset: X-ray 다중 객체 인식 데이터. [3]

- Qualitative Results

	ConvNeXt	ConvNeXt with MoE
Trainable Params	115M	24.4M
Non-Trainable Params	729M	157K
Total Params	844M	24.5M
Total Estimated Model Size (MB)	3,378.42	98.105
Modules in Train Mode	517	143

- Quantitative Results

- 이 결과는 MoE 모델이 정확도와 F1 점수 측면에서 ConvNeXt 모델을 능가한다는 것을 보여줍니다.



CONCLUSIONS

Contributions and Conclusions

- ConvNeXt와 MoE를 사용하여 파라미터를 97% 이상 줄이면서도 성능을 유지합니다.
- 이를 통해 자원이 제한된 환경에서도 실시간 애플리케이션 구현이 가능함을 보여줍니다
- 향후 성능 향상은 튜닝 및 최적화 전략을 통해 이루어질 수 있습니다..

References

- "A ConvNet for the 2020s, Zhuang Liu et al., CVPR 2022
- "Outrageously Large Neural Networks", Geoffrey Hinton et al., ICLR 2017
- Alhub X-ray 다중 객체 인식 데이터.,