

Small-Math-R1: 수학 추론을 위한 경량 RL모델

이재건, 최장훈*
경북대학교 데이터사이언스대학원
leejken530@knu.ac.kr, jhchoi09@knu.ac.kr

Abstract

본 연구는 수학 문제 해결에 특화된 소형 추론 모델 Small-Math-R1을 제안한다.

모델 학습은 두 단계로 구성된다.

▶ 첫 단계에서는 수학 도메인 특화 멀티모달 데이터셋을 이용해 지도 미세조정(SFT)을 수행하여 cold-start 문제를 완화한다.

▶ 두 번째 단계에서 Adjusted GRPO (Adjusted Group Reward Policy Optimization) 강화학습을 적용한다. Adjusted GRPO는 기존 GRPO의 objective를 수정하여 (i) 분모를 생성된 총 토큰 수로 $\sum_{i=1}^G |o_i|$ 변경해 긴 추론을 장려하고, (ii) 참조 정책과의 KL 발산 패널티 $-\beta D_{KL}$ 를 제거해 정책이 보다 자유롭게 탐색하도록 유도한다.

또한 형식, 길이, 정답의 세 요소로 구성된 구조화된 보상 함수를 설계하여 모델의 행동을 정교하게 제어한다.

실험 결과, 제안된 방법은 제한된 연산 자원 환경에서도 basemodel Qwen-VL-3B 보다 훨씬 높은 정확도를 보여주었다.

Methodology

A. 기존GRPO => AdjustGRPO

$$J_{GRPO}(\theta) = \frac{1}{G} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left[r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1-\epsilon, 1+\epsilon) \hat{A}_{i,t} \right] - \beta D_{KL}(\pi_{\theta} \parallel \pi_{\text{ref}}) \quad \textcircled{1}$$

- 현재 정책의 파라미터: θ
- 배치 내 trajectory 의 갯수: G
- i번째 trajectory에서의 출력 시퀀스: O_i
- 현재 정책: π_{θ}
- 참조 정책: π_{ref}
- KL Divergence: $D_{KL}(\pi_{\theta} \parallel \pi_{\text{ref}})$
- 확률비율: $r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} | o_{i,<t})}{\pi_{\text{old}}(o_{i,t} | o_{i,<t})}$
- 보상정규화: $\hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_j\}_{j=1}^G)}{\text{std}(\{R_j\}_{j=1}^G)}$

$$\mathcal{J}_{AJ}(\theta) = \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\} \sim \pi_{\text{old}}} \left[\frac{1}{\sum_{j=1}^G |o_j|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \cdot \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1-\epsilon, 1+\epsilon) \cdot \hat{A}_{i,t} \right) \right] \quad \textcircled{2}$$


→ ① 기존GRPO 에서 KL 패널티를 제거 $-\beta D_{KL}(\pi_{\theta} \parallel \pi_{\text{ref}})$, ② 토큰 길이 기반 가중치로 나눔으로써 $\frac{1}{\sum_{j=1}^G |o_j|}$ 모델이 조금 더 탐구적(exploration)으로 탐색할 수 있게끔 하였습니다.

B. Reward 설계


$$R = \begin{cases} AR + FR, & \text{if } FR > 0 \text{ and } AR = r_2 \\ -FR, & \text{if } FR > 0 \text{ and } AR = 0 \\ -(r_0 + r_1 + r_2), & \text{if } FR = 0 \end{cases} \quad FR = r_0 + r_{\{\text{ratio}\}} \cdot r_1, \quad AR = r_2$$

▶ 형식(FR)을 틀리면 무조건 틀리게, 정답(AR)과 형식(FR)이 맞아떨어지면 reward 받게끔 구성하였습니다.

Experimental Results



난이도별 정확도 비교



주제별 정확도 비교